



*Rozproszony algorytm genetyczny do  
wyszukiwania globalnej ekstremy: MPI  
Programowanie równoległe i rozproszone*

Wykonanie:

1. Ivan Prapakets
2. Piotr Jeleniewicz

Sprawdzająca:

dr inż. Zuzanna Krawczyk

Warszawa, 2020

## Spis treści

1	Opis uruchomienia i wywołania programu	2
2	Dokładny opis realizacji problemu	2
3	Testy programu pokazujące np. uzyskane przyspieszenie	5
4	Wnioski	5

## 1 Opis uruchomienia i wywołania programu

Aby uruchomić program i otworzyć GUI trzeba wpisać komendę: `python3 main.py` lub poprzez IDE np. PyCharm.

Po uruchomieniu programu i otworzeniu ustawienia-GUI z kilkoma polami:

- `f(x, y)` input string
- `chromosomes`
- `generations number` input string liczba pokoleń
- `optimizer function (min or max)` funkcja optymalizatora (min lub max)

Oraz pola z ptaszkami (funkcjonalne):

- `mutation` - dodanie mutacji do każdej części (4 osobników) nowego pokolenia
- `show statistics` - pokazuje dokładne informacje o każdym pokoleniu
- `save all files` - zapisuje do folderu `results` statystyki wyników z animacją w `.gif` oraz `ga-statystyki` + do folderu `generations` dane csv z kolumnami `x, y, f (x, y)`
- `show plot` - pokazuje animację ewaluacji

## 2 Dokładny opis realizacji problemu

### Opis programu

Program w przybliżeniu oblicza minimum lub maksimum funkcji o dwóch parametrach na podstawie algorytmu genetycznego. Każdy osobnik ma jedną `chromosom (x, y)` i ze względu na to, że osobnik i `chromosom` mają to samo znaczenie, pokolenie składa się z części, gdzie jedna część to 4 osobniki, w

konsekwencji liczba chromosomów jest wielokrotnością 4.

Zasada crossover to:

$(x\_better, y\_best)$ ,  $(y\_better, y\_best)$ ,  $(x\_best, y\_better)$ ,  $(x\_best, y\_good)$

gdzie  $(x\_best, y\_best)$ ,  $(x\_better, y\_better)$ ,  $(x\_good, y\_good)$  są zaznaczonymi individs.

### **Funkcji genetyczne i rozwiązanie algorytmiczne.**

W tej chwili w programie realizowany jest genetyczny algorytm, który jest parametryzowany przez dane wejściowe za pomocą GUI.


Pojedynczy osobnik przenosi w każdym swoim genie informacje o odpowiedniej współrzędnej X lub Y. Populacja jest określana przez wiele osobników, ale populacja jest podzielona na 4 osobniki. To rozwiązanie jest spowodowane próbą uniknięcia zbieżności do lokalnego optimum, ponieważ jest to zadanie o znalezieniu globalnego ekstremum. Taki podział, w wielu przypadkach nie pozwala zdominować jednego genotypu w całej populacji, ale wręcz przeciwnie, daje **ewolucję** większą dynamikę. Dla każdej takiej części populacji stosuje się następujący algorytm:

1. Selekcja jest podobna do metody rankingowej. Wybiera się 3 osobniki o najlepszych wskaźnikach funkcji fitness (tzn. dokonuje się sortowania osobników w kolejności rosnącej/malejącej określonej przez użytkownika funkcji),
2. Następnie stosuje się funkcję krzyżowania w taki sposób, że nowa generacja (dokładniej nowy segment populacji 4 osobników) otrzymuje 2 pary niezmutowanych genów od osobnika o lepszym odczycie funkcji fitness i po parze zmutowanych genów od pozostałych dwóch osobni-


ków.

Zasada selekcji, krzyżowania i mutacji wyraźnie wygląda tak (w generacji N chromosomów osobników są już posortowane w odpowiedniej kolejności, a mały czarny kwadrat oznacza mutację):

Generacja N



Generacja N + 1



### 3 Testy programu pokazujące np. uzyskane przyspieszenie

#### Funkcja 1

$$f(x, y) = \sin(x) + \cos(y)$$

#### Funkcja 2

$$\frac{4\sqrt{x} - 5y}{3x^2 + 2y^2 - 2x + 1}$$

#### Funkcja 3

$$f(x, y) = \sin x$$

#### Funkcja 4

$$f(x, y) = 4\exp(-x^2 - y^2)$$

$$f(x, y) = (\sqrt{x} - 5y)/(x^2 + y^2 - 2x + 10)$$

### 4 Wnioski

1. Właściwy zestaw parametrów pozwala na dość dokładne znalezienie globalnego ekstremum funkcji z dwóch zmiennych
2. Wizualizacja może pomóc w debugowaniu i ulepszaniu algorytmu, a także pomaga zrozumieć przebieg i zasady samego algorytmu genetycznego
3. Udało nam się poprawnie zrównoleglić algorytm genetyczny i odpowiednio dobrać parametry aby osiągnąć przyspieszenie

